


공인중개사 업무 지원 시스템

음성 입력 자동화와 멀티에이전트 중개 판단을 연결하는 개발·시연용 아키텍처



음성에서 장부로, 장부에서 중개 판단으로


F1 장부를 공통 데이터 기반으로 삼아 F2가 입력을 돕고, F3가 양측의 조건과 상담 근거를 비교합니다. F4는 장부·일정을 자연어로 조회합니다.

이 문서가 보여주는 상태

현재 코드와 승인 설계를 함께 설명합니다. 기반 자원 적용과 최신 앱 배포, 모델 활성화, 실제 추론 검증은 별도로 판정합니다. 상세 상태는 7쪽에 정리했습니다.

서버·네트워크·저장소

배포 경계와 데이터 소유권을 나누어 구성 요소의 위치를 읽습니다.



저장소·자원	책임 및 접근 방식	현재 상태·해석
RDS / pgvector	장부, 상담 로그, F3 작업·카드·판정, F4 대화·요청 저장	RDS Single-AZ · DB subnet group 2개 AZ. pgvector 기반과 실제 의미 검색 사용은 구분
목적별 private S3	웹 정적 파일 / 데이터·모델 / Pipeline artifact / 음성용 버킷	버킷 기반 적용. 현재 F2 업로드는 서버 임시 파일로 처리 후 삭제
EC2 · RDS 용량	EC2 t3.small · gp3 40GiB / RDS db.t4g.small · 20→최대50GiB	단일 앱 호스트·Single-AZ의 개발 환경. 무중단·고가용성 보장 아님

CloudFront→ALB origin은 HTTP이며 ALB ingress는 CloudFront origin-facing 대역으로 제한합니다. 현재 환경은 합성·비식별 데이터 시연을 전제로 합니다.

기능별 요청·데이터 흐름


공통 웹·API 진입 이후, 기능마다 다른 실행·저장 경로를 사용합니다.

F1 장부 조회·저장



Backend가 영속성과 권한을 소유하며, F2·F3는 F1에 저장된 데이터를 통해 연결됩니다.

F2 음성 분석·승인



API가 분석 결과를 기다려 응답합니다. 동시 분석 1건 · 혼잡 시 재시도 · endpoint offline 시 503.

F3 중개 판정



저장은 앵커 카드까지만 준비합니다. 후보 추출·교차 판정은 사용자가 판정을 요청한 뒤 진행합니다.

F4 챗봇 조회



F3 Worker와 별도 경로입니다. 결과는 DB에 저장해 재접속 때 복원하며, F2 이동은 사용자 클릭으로 연결합니다.

양측 포지션에서 중개 판정까지

에이전트의 역할 분리와 Backend의 실행·영속성 책임을 함께 표현합니다.




책임	현재 구현	운영·검증 경계
실행·재개	Backend Worker가 RDS의 저장 상태를 따라 단계를 실행	lease·입력 버전·재시도 검증. 후보 0건이면 AI 판정 없이 완료
근거·판정	측면별 구조화 카드와 앵커·후보 전체 비교 판정	등급·순위·걸림돌·양보 지점·근거를 검증 후 저장
LangGraph	의존성 및 채택 결정 존재	전체 운영 그래프·checkpointer 구현 전. 현재는 Worker 상태 기반 실행

현재 F3 실행은 명시적 합성 프로토타입 opt-in을 요구합니다. 실사용 상담 로그의 마스킹 전환과 운영 모델 승격 기준은 별도 완료 조건입니다.

모델 서빙·모델 전달

등록된 산출물, 선택한 모델, 실제 실행·품질 검증을 서로 다른 단계로 관리합니다.



용도	모델·실행 경로	기준일에 확인한 상태
F2 · STT	Whisper large-v3-turbo F2 Pod의 STT vLLM 프로세스	Template 모델·revision 고정. 공유 기동·앱 경유 추론은 별도 검증
F2 · 상담 추출	Qwen3-4B + consultation-v3 LoRA STT 전사에서 유형·장부 필드·근거 추출	번들 검증·catalog 등록·S3 게시 기록 있음. RunPod RTX A5000 선택 저장, endpoint offline 기록
범용 · F3 / F4	Qwen3.8-27B-FP8 프로파일 RunPod L40S 선택 / AWS GPU 대체 경로	RunPod 고정 합성 평가 이력 있음. 공유 선택 저장과 실제 DB 활성 모델은 별개. AWS 왕복 검증 미완료
기타 Provider	OpenAI: local 개발 경로 Bedrock: Instance Role·SigV4 경로	adapter 구현·Bedrock IAM 기반 적용 기록. 실제 활성 모델·최신 앱 추론 검증은 별도 확인 필요

실행 단위와 연결

F2는 한 GPU에서 STT·추출 프로세스를 분리합니다. general은 별도 작업으로 선택하며, 앱에는 Provider adapter를 통해 연결합니다.

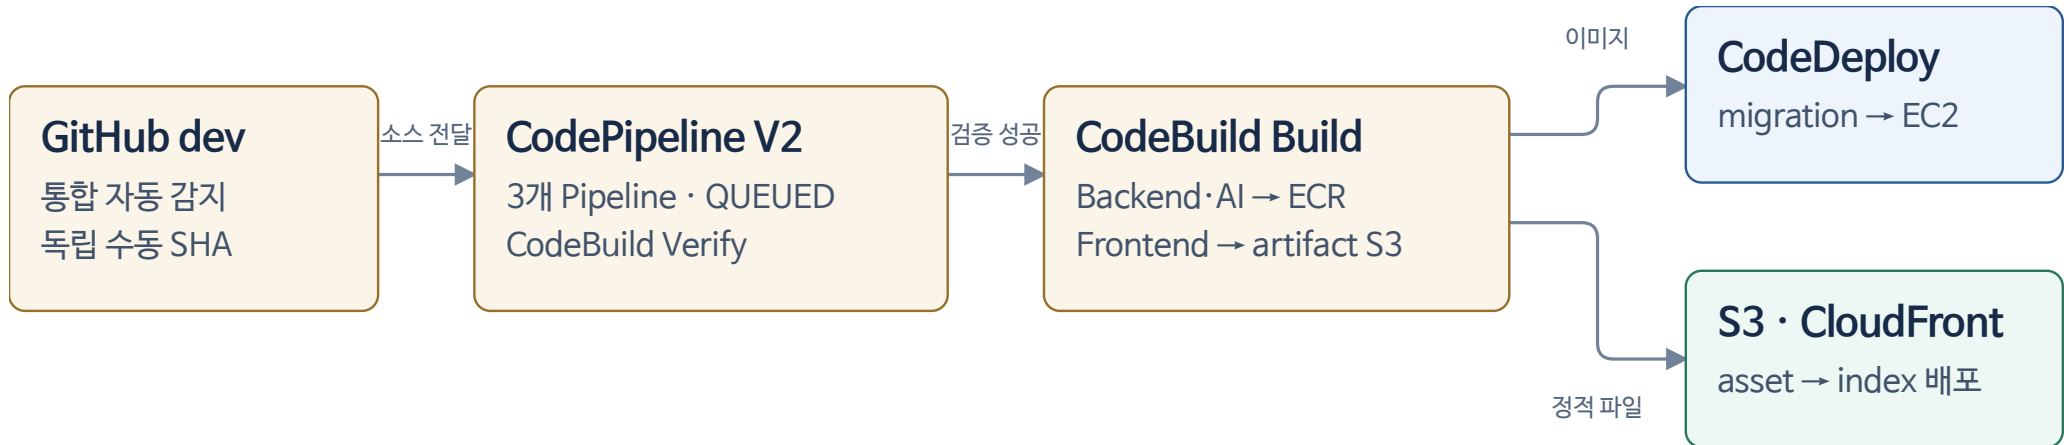
평가와 운영 활성화는 별도

공식 FP8은 기존 HTTP 평가를 통과했지만 모델 평가의 일부 기준은 미달했습니다. 이전 평가를 최신 이미지·프롬프트의 검증 완료로 옮겨 적지 않습니다.

가중치는 고정 revision으로 확보하며 이미지에 모두 포함하지 않습니다. 모델·클라우드는 명시적으로 선택하고 자동 fallback하지 않습니다.

배포·보안·운영

검증된 애플리케이션을 전달하고, 실행 중 오류와 자원 수명주기를 관리합니다.



배포·복구

- API·Worker·migration은 같은 이미지 digest를 사용합니다. DB migration 성공 후 앱 기동을 진행합니다.
- Backend 실패 시 정상 앱 revision으로 복구합니다. DB down migration은 자동 실행하지 않습니다.
- Frontend는 asset을 먼저 올리고 index를 마지막에 교체합니다. 실패하면 이전 index를 복원합니다.
- Terraform은 수동 plan 검토·승인·apply 경로로 관리하며 앱 Pipeline에 포함하지 않습니다.

보안·관측·전원 관리

- Secrets Manager와 Parameter Store에서 프로세스별 설정을 주입하고 이미지에 비밀 값을 포함하지 않습니다.
- Backend 오류·AI 최종 실패 → CloudWatch → SNS → Lambda → Discord 알림 경로를 사용합니다.
- 일반 종료는 앱·RDS·관리 GPU를 정지·정리합니다. RunPod는 운영자가 시작·종료를 확인합니다.
- deep 중지 중에는 ALB 제거·CloudFront 비활성화와 자동 배포 감지 중지를 적용합니다.

기반 적용 이후에도 남는 검증

3개 Pipeline과 배포 기반은 적용 기록이 있습니다. 최신 코드의 정식 앱 배포, 최초 전환, 기동·추론 확인은 개별 운영 기록으로 검증해야 합니다. 이 문서 작성 과정에서는 배포와 클라우드 기동을 수행하지 않았습니다.

기술 명세와 확인 범위

버전은 lockfile 확정값을 기본으로 쓰고, 환경 기록·요구 범위·미확인 항목을 따로 표시합니다.

기술 스택

기술	확인 버전 / 용도
React / Vite	19.2.0 / 6.4.2 · 웹 UI·빌드
TypeScript	5.9.3 · Frontend lock 확정
Python	3.13 계열 · 프로젝트 요구 범위
FastAPI / Uvicorn	0.141.1 / 0.52.3 · HTTP 서버
SQLModel / Yoyo	0.0.39 / 9.0.0 · ORM·SQL migration
PostgreSQL	15.18 · 인프라 적용 기록
LangGraph	1.2.11 · lock 포함, 전체 운영 그래프 미구현
vLLM	0.28.0 · 범용 비교 환경 기준
Terraform / Docker	IaC / 앱·서빙 패키징 · 실행 버전 미확인

구현·적용·검증 상태

상태	확인 범위와 남은 조건
코드 구현	F1·F2·F3 및 F4 조회·SSE 경로. F4는 기본 비활성 기록
기반 적용	VPC·앱/edge·RDS·S3·3개 Pipeline·관측·설정 기반
선택 저장	F2 consultation-v3 / general FP8 선택. endpoint offline 기록
평가 이력	RunPod 범용 모델 비교 완료. FP8의 일부 모델 평가 기준 미달
배포·검증 대기	최신 앱·서빙 이미지, 공유 기동·추론·DB 활성 모델·왕복 전환
조건부·미구현	ECS·SQS 조건부 / F3 전체 LangGraph·checkpoint 미구현

코드 기준: 618c75610a14 · 인프라 기록: 2026.09.09
실시간 전원 상태를 새로 조회한 보고서가 아닙니다.

근거 자료 문서명의 링크는 작성 기준 commit의 저장소 원문으로 연결됩니다.

- S1 인프라 구조·배포 · 원문 1 / 원문 2
- S3 F2 API·분석 파이프라인 · 원문 1 / 원문 2
- S5 F4 실행·검증 · 원문 1 / 원문 2
- S7 승인 결정·고정 의존성 · 원문 1 / 원문 2

- S2 적용 인벤토리·운영 · 원문 1 / 원문 2
- S4 F3 구현·Worker · 원문 1 / 원문 2
- S6 모델 비교·release · 원문 1 / 원문 2
- 추가 Frontend lock / AI lock / STT Template

이전 기수 문서는 항목·형식 참고에만 사용했습니다. 작성: 30기 3팀 · 작성 기준일: 2026.09.10 · 제출일 별도. 구성·상태는 저장소 근거에 한정합니다.