

F3 멀티 에이전트 테스트 계획 및 결과 보고서

공인중개사 업무 지원 플랫폼 · 매물 대리 · 손님 대리 · 중개 판정

이 보고서는 무엇을 어떤 기준으로 시험하는가(계획)와 현재까지 실제로 측정된 것이 무엇인가(결과)를 구분해 기술한다. 아직 측정하지 못한 지표는 빈칸으로 두지 않고 차단 사유와 선행 조건을 함께 적는다. 측정하지 않은 값을 추정치로 채우지 않는다.

문서 번호	F3-TEST-001 · v1.0
대상 기능	F3 비서 에이전트 (매물 대리 · 손님 대리 · 중개 판정)
기준 문서	MVP 요구사항 정의서 v1.0 · F3 수용 기준 15항 · F3 오프라인 데이터·평가 아키텍처
대상 저장소	SKN30-FINAL-3Team (ai · backend · frontend · infra)
작성일	2026-08-28

01 목적과 범위

이 보고서가 답하는 질문

F3는 하나의 모델이 답을 만드는 구조가 아니라, **관측 범위가 서로 분리된 대리 에이전트 2종과 양측 카드만 비교하는 중개 판정 에이전트 1종**, 그리고 그 사이의 **결정적 코드 구간**(후보 추출 · 날짜 산출 · 등급 산출)으로 이루어진다. 따라서 "잘 되는가"를 한 개의 점수로 물으면 실패 원인을 찾을 수 없다. 이 보고서는 질문을 네 개로 나눈다.

- 규칙대로 후보와 근거를 **회수**했는가
- 각 대리가 **허용된 측면의 데이터만** 써서 입장과 근거를 구조화했는가
- 중개 판정이 양측을 비교해 **쓸모 있는 판단**(걸림돌·양보 지점·행동)을 냈는가
- 같은 입력에 같은 결과가 나오고, F3가 죽어도 F1이 사는가 — **재현성과 경계**

포함 범위

구분	내용
포함	F3 교차 판정(A군) 전 구간 — 포지션 카드 생성, 결정적 SQL 후보 추출, 후보 카드, 중개 판정, 등급 산출, 캐시·무효화, 대리 격리, F1과의 장애 경계
제외	캠페인(배치 판정, B군) — 2026-08-17 결정으로 P2 강등. 대리 하나를 N번 돌리는 구조여서 멀티 에이전트 논증에 기여하지 않는다 (수용 기준 18.1 주의사항). 수용 기준 11·12는 이번 시험 대상이 아니다.
참조만	F2 sLLM 평가(별도 보고), F1 장부 기능(경계 시험 대상으로만 등장)

시험 대상 시스템

계층	구성	이 보고서에서의 취급
Frontend	React 19 + AG Grid + PatternFly. [손님 찾기] / [매물 찾기] 버튼이 판정을 발동한다	발동 트리거 확인만
Backend	FastAPI. API 프로세스와 Worker 프로세스 분리. 상태 기계 QUEUED → ... → COMPLETED / FAILED_TERMINAL / SUPERSEDED	계약·상태·경계 시험
AI	<code>brokerage-ai</code> 파이썬 라이브러리(독립 서버 없음). Provider Registry(vLLM · OpenAI)	카드·판정 품질 시험
Data	RDS PostgreSQL 15.18 + pgvector. 합성 장부 시드(migrate 010)	데이터셋 무결성 시험

용어 — 이 보고서에서 "멀티 에이전트"의 정의

에이전트끼리 대화하거나 스스로 도구를 고르는 구조가 아니다. **역할과 관측 범위를 분리한 다중 에이전트 파이프라인**이며, 시험이 입증하려는 우위도 자율성이 아니라 **격리 · 근거 추적성 · 재현 가능한 등급** 세 가지다. 시험 항목은 이 세 가지를 겨냥해 설계했다.

02 시험 전략

시험을 네 계층으로 나눈다. 위 계층이 통과해야 아래 계층의 실패가 해석 가능해진다.

L1 결정적 코드 후보 추출 · 인도 가능일 · 마감일 · 하드 게이트 · 5축 점수 · 등급. LLM이 관여하지 않는다. 같은 입력에 항상 같은 값이어야 하며, 틀리면 원인은 코드다.	L2 계약과 격리 구조화 출력 스키마 준수, 대리 입력에 반대편 자료가 섞이지 않음, 근거가 원본 로그 행을 가리킴, 캐시 키 · 상태 전이.	L3 판단 품질 포지션 카드의 항목 정확도와 근거 지지율, 중개 판정의 걸림돌·양보 지점 구체성, 단일 프롬프트 기준선 대비 블라인드 선호.	L4 중단·운영 응답 시간, 호출·토큰 비용, 재시작 후 복구, 캐시 무효화, F3 중단 시 F1 정상 동작.
---	---	--	---

실패 원인을 반드시 갈라 본다

증상	원인 판별 규칙
후보가 틀림	기대 근거가 검색 결과에 없으면 검색 실패 , 근거는 있는데 카드·판정이 틀리면 추론 실패 . 두 실패를 한 지표에 합치지 않는다.
등급이 틀림	인도 가능일 · 평형 · 게이트 값이 기대표와 다르면 코드 문제 . 그 값들은 맞는데 등급이 다르면 카드의 <code>intent</code> · <code>price_est</code> · <code>contact</code> 를 본다 → 모델 문제 .
재실행에 결과가 흔들림	등급 산출에는 난수도 시각 조회도 없다. 흔들리면 등급이 카드에 과의존 하거나 판정 호출이 등급에 영향을 준 것이며, 이는 설계 위반이다.
타임아웃 · 파싱 실패	평가에서 제외하지 않고 별도 오류로 집계 한다. 실패를 표본에서 빼면 품질이 좋아 보인다.

측정의 무결성 규칙

- 기준선(단일 프롬프트)과 후보(멀티 에이전트)는 **같은 구조화 데이터 · 로그 스냅샷 · 검색 결과 · 모델 계열 · 출력 예산**을 쓴다.
- 블라인드 비교에서는 출력에서 **구성 이름을 제거하고 A/B 위치를 무작위화**한다.
- 결과를 본 뒤 유리한 top-K나 slice로 **최종 평가를 다시 정의하지 않는다**.
- 같은 **숨김 최종셋을 반복 튜닝에 사용하지 않는다**. 새 오류 사례는 다음 데이터셋 버전에 넣는다.
- 모델 · 프롬프트 · 워크플로 · 검색 버전을 결과와 함께 기록한다.

이번 판의 가장 큰 제약 — 결과를 읽을 때 반드시 함께 볼 것
현재 실측된 결과의 대부분은 **mock 백엔드**로 얻었다. mock은 화자 규칙 R1~R4의 **참조 구현**이며, 이것으로 검증되는 것은 **L1·L2(코드와 계약)**이지 L3(모델 품질)이 아니다. mock 통과는 "규칙이 맞게 짜였다"는 뜻이고, 실제 모델이 그 규칙을 지키는지는 별개의 측정이다.

03 시험 환경과 데이터셋

합성 장부 데이터셋

가상 아파트 「한들마을 센트럴파크」 (3,206세대 · 48개동 · 2020-11 준공)를 기준으로 만든 합성 장부다. 단지명 · 동호 · 인물 · 금액은 전부 합성이고, 실제 공개 정보에서 가져온 것은 제원과 시세 대역뿐이므로 **시세 근거로는 사용할 수 없다**. 실존 인물·주소는 없고 전화번호는 국내 미할당 010-0 대역만 쓴다.

항목	건수	비고
세대 / 매물	20 / 20	A군 13케이스가 갈리도록 가격·시점·평형·의향을 설계
구입장(손님)	6	C01(22.0억·33평) · C04(31.0억·43평) · C05(마감 2026-11-30) 등
인물 / 연락처 / 관계	37 / 36 / 29	화자 ①②③의 원천은 로그 텍스트가 아니라 <code>property_unit_party_relation.role_index</code>
상담 로그	188	케이스 55 + 배경 112 + 구입장 21. 배경 로그는 합성 상담로그 500건 데이터셋의 실제 문장

분할 규칙 — 누수 차단

동일 인물 · 세대 · 상담 원천 · 파생 문장 · 유사 시나리오가 분할을 넘지 않도록 **출처 그룹을 먼저** 배정한다.

분할	용도	격리 규칙
dev	프롬프트 · 검색 · 워크플로 선택과 오류 분석	반복 확인 허용. hidden final의 파생 사례 금지
hidden final	최종 구조 비교와 품질 결론	정답과 A/B 식별을 평가 실행자·개발자에게 숨김
performance	SQL · 검색 지연과 용량 검증	품질 정답과 분리. 규모·분포·인덱스 상태 고정

실행 환경

환경	구성	비용
프로토타입 (mock)	06_프로토타입_F3플로우 — 장부 로더 + 대리 2종 + 판정 + 등급 산출. LLM 자리에 화자 규칙 R1~R4 참조 구현	API 키 불필요
프로토타입 (openai)	같은 코드에 실제 Provider 연결. 대리 gpt-4o-mini · 판정 gpt-4o	키 필요
본 저장소 · API-only	로컬 PostgreSQL + Backend(Worker 정지). 인증 · CSRF · 실행 접수 · 합성 실행 재사용 · 상태 조회	키 불필요
본 저장소 · 전체 파이프라인	Worker 기동. 카드 → SQL 후보 → 후보 카드 → 중개 판정 → 결과 저장	키 필요

데이터 규칙

이 절차는 **합성 데이터에만** 사용한다. 실제 고객 이름 · 연락처 · 상담 원문이나 운영 DB 데이터를 넣지 않는다.
F3_ALLOW_SYNTHETIC_PROTOTYPE=true 는 데이터가 합성임을 코드가 증명한다는 뜻이 아니라 **실행자가 합성 전용 DB임을 확인했다는 선언**이다. 전체 프롬프트 · 전체 모델 응답 · 상담 원문은 로그에 남기지 않는다.

04 시험 항목 — 수용 기준 15항 매핑

F3 수용 기준 각 항목을 시험 계층 · 검증 방법 · 판정 기준에 매핑한다. 현재 상태는 7장에서 결과와 함께 다시 표로 정리한다.

#	수용 기준	계층	검증 방법	합격 판정 기준
1	후보 추출과 대상 선정이 LLM 없이 동작한다	L1	유닛 테스트 · 게이트 값 대조	표기/추정 두 기준의 게이트 금액과 후보 집합이 기대표와 완전 일치
2	카드의 각 판정 항목에 근거 원문이 있거나 「추정」으로 표시된다	L2·L3	표본 20건 검수	근거 지지 90% 이상 · 무근거 단정 0건
3	매물 대리와 손님 대리가 서로의 로그를 읽지 않는다	L2	실행 로그 · 입력 검사	반대편 자료 유입 0건 (허용 오차 없음)
4	양측 대리 방식이 단일 프롬프트 대비 우수하다	L3	동일 케이스 20건 블라인드 A/B	블라인드 선호 60% 이상
5	중개 판정이 앵커 1 + 후보 N을 한 번의 호출로 받는다	L2·L4	호출 계측	판정 호출 = 1회. 2회 이상이면 상호 비교 근거가 성립하지 않음
6	후보 중 일부를 기각하며 사유가 로그에 남는다	L1·L2	실행 로그	하드 게이트 G1~G5 발동 시 기각 + 사유 문자열 기록
7	후보 추출 조건에 대리의 추정값이 반영된다	L1·L2	장부 표기값과 다른 케이스 재현	상한이 추정 23.5억으로 잡히고, 표기 22.0억 기준에서는 누락되던 매물이 후보로 진입
8	저장 후 5초 이내 같은 화면에 결과가 표시된다	L4	성능 측정	5초 내 단계/완료 비율. 임계값 미승인 — 6장 참조
9	교차 판정 결과에 컷이 없다	L1	판정 수 = 노출 수 + 기각 수 대조	기각 후보가 응답에서 사라지지 않음
10	가격 변경 저장 시 새로 조건에 맞게 된 상대가 결과에 포함된다	L1	가격 인하 시나리오	인하 전 게이트 밖 → 인하 후 후보 진입 및 등급 산출
11	캠페인 100명에서 발송 제외 대상이 근거와 함께 식별된다	—	—	범위 밖 B군 P2 강등
12	캠페인 100명의 문안 생성 LLM 호출이 10회 이하다	—	—	범위 밖 B군 P2 강등
13	카드가 캐시되어 로그 변경이 없으면 재생성되지 않는다	L2·L4	캐시 히트율 계측	동일 요청 2회차 cache_hit: true · 모델 호출 0회. 로그 추가 시 즉시 무효화
14	중개사가 정정한 포지션이 다음 판정에 반영된다	L2	정정 → 재판정 시나리오	관계·값 수정 후 캐시 무효화 및 등급 변동
15	F3를 중단해도 F1의 모든 기능이 동작한다	L4	장애 주입	F1 조작·저장·편집 정상, F3만 503 AI_UNAVAILABLE

아키텍처 동작 시험 (품질 평가와 별도)

다음은 판정 품질이 아니라 시스템 동작을 확인하는 항목이며, 자동 또는 장애 주입으로 검증한다.

- 손님/매물 저장과 손님/세대 상세의 [교차 판정] 버튼으로 구성된 네 개의 트리거
- 5초 초과 시 앵커 · SQL 후보 · 진행률의 부분 표시와 F1 비차단
- 후보 없음 · 5건 초과 페이징 · 가격 변경 후 새 후보 유입
- 일부 후보 카드 실패, 중개 모델 실패, 임베딩 생성·검색 실패
- 임베딩 인덱스 지연·재색인 중 전문검색 폴백
- Worker · API 재시작 후 영속 작업 복구와 중복 호출 방지
- 로그·가격·상태·조건 변경에 따른 캐시 무효화와 SUPERSEDED 실행
- 대리 도구 격리와 중개 판정의 도구 미보유

05 지표와 합격선

계층별 보고 지표

계층	핵심 질문	보고 지표
후보 SQL	맞는 후보를 빠짐없이 규칙대로 찾았는가	Recall@K · Precision@K · 필터 위반률 · 순서 일치 · 지연
로그 검색	필요한 원문과 최신 문맥을 회수했는가	근거 Recall@K · 무관 근거율 · 철회·부정 오회수율 · 최신 진술 보존
포지션 카드	허용 측면에서 실제 입장과 근거를 구조화했는가	항목별 정확도·F1 · 근거 지지율 · 무근거 단정률 · 「불명/추정」 적절성
중개 판정	전체 후보를 비교해 유용한 판단을 내는가	등급·기각 오류 · 걸림돌/양보/행동 rubric · 블라인드 선호
경계·신뢰	정보 격리와 추적이 지켜졌는가	반대편 도구 호출 0건 · 근거 추적 성공률 · 권한·마스킹 위반률
종단·운영	사용자 경험과 비용 목표를 만족하는가	5초 내 완료 비율 · 총 지연 · 호출 수·토큰 · 캐시 재사용 · 실패·재시도율

MVP 요구사항 정의서 v1.0이 정한 정량 합격선

지표	합격선	표본	본 보고서에서의 상태
F3 SQL 후보 일치	100%	전 케이스	부분 프로토타입 기준 일치. 본 저장소 실행 대조 미실시
F3 근거 지지	90%	20건	미측정 실모델 카드 20건 검수 필요
멀티 에이전트 블라인드 선호	60%	20건	미측정 기준선 경로 미구현
종단간 시연	5회 연속 성공	5회	미측정 전체 파이프라인 실행 필요
F2 분류 Macro-F1	0.85	100건	별도 보고 F2 sLLM 평가
F2 추출 Micro-F1 / 무근거 생성	0.80 / 2% 이하	100건	별도 보고 F2 sLLM 평가

합격선에 대한 두 가지 유보 — 결과를 발표할 때 함께 말해야 한다

- (1) 표본 20건에서 60% 선호는 통계적으로 유의하지 않다. 귀무가설(선호 50%) 하에서 20건 중 12건 이상이 나올 확률은 대략 0.25다. 즉 이 수치는 방향을 보는 지표이지 우위의 증거가 아니며, 보고 시 신뢰구간과 함께 제시한다.
- (2) 평가자가 1인이므로 평가자 간 일치도를 제공할 수 없다. 이 점을 결과의 한계로 명시한다. 두 유보는 감추는 것이 아니라 **보고서에 적어 두는 편이 방어에 유리하다**.

아직 승인되지 않은 임계값

응답 시간(수용 기준 8의 「5초」)은 현재 MVP 요구사항 정의서 5장 비기능 항목에 **성능 요구로 등재되어 있지 않다**. 기준선 측정 전에는 임의 수치를 합격선으로 사용하지 않는다는 원칙에 따라, 이 보고서는 5초를 **목표**로 기재하고 합격선으로는 쓰지 않는다.

06 시험 결과 — 실측

2026-08-28 기준으로 실제 실행해 확인한 것만 신는다. 재현 명령을 함께 적는다.

13 / 13

A군 케이스 자동 검증 통과

0 / 28

대리 호출 중 반대편 로그 유입

188

시드 상담 로그 (케이스 55 · 배경 112 · 구입장 21)

348 / 646

저장소 테스트 통과 / 수집 (297건은 DB 미연결로 건너뛴)

6.1 A군 13케이스 자동 검증 통과

python run.py · mock 백엔드 · 앵커 전수. 기대 결과는 ledger.json 의 매물별 expect 에 있고 판정에는 쓰지 않고 대조만 한다.

케이스	확인 대상	결과	판정
A-1-1	표기 예산 < 실제 상한	M08(26.4억)이 추정 기준에서만 후보로 진입	OK
A-1-2	가격은 맞는데 시점이 안 맞음	앵커 교체로 등급이 뒤집힌 매물 M01 · M04 · M19	OK
A-1-3	가격 인하 후 재조회	인하 전 후보 제외 → 인하 후 「중간」으로 진입	OK
A-1-4	양보 폭 산출	양보 1.5억이 가격 축을 10.0 → 22.0점으로 올림 (중간 → 강함)	OK
A-2-1	의향 철회 · 화자 규칙	M20 기각 · M01 중간 (기대와 일치)	OK
A-2-2	만기 임박 + 결정 앞둠	M09 강함 91.0점. 임차 만기 2026-11-30(D-105)을 코드가 산출	OK
A-2-3	시점 불일치 기각	M02 기각 — G4 인도 2027-06-15 > 마감 2027-03-02 (105일 초과)	OK
A-2-4	조건부 자금 — 순서가 있는 성사	M10 중간 80.8점. 선행 매수 미확정 → 인도일 판정 불가 + 보류 게이트	OK
A-3-1	응대자에게 결정권 없음	M07 중간 85.0점. 최근 진술이 임차인 발화뿐 → 기각이 아니라 1단계 강등	OK
A-3-2	공동명의 단독 결정 불가	M01 중간 79.0점. 주①(24.5억)과 주②(23.3억)를 덮지 않고 병기	OK
A-3-3	관계 수정 → 카드 무효화	관계 수정으로 중간 → 강함 상승	OK
A-4-1	접촉 경로 판정 (화자별)	M12 강함 97.0점. 주①(불가·5건) · 주②(양호·5건) → 경로 주② 세대 단위로 뭉치면 「주의」가 되어 틀린다	OK
A-4-2	접촉 가능 상태 강등	M13 중간 91.0점. 가격·시점 만점이나 4회 연속 무응답 → 접촉 축 2점 + 보류 게이트	OK

6.2 대리 격리 통과

같은 실행에서 대리 호출 28회 중 반대편 로그가 입력에 섞인 사례 0건. 격리는 프롬프트 문구가 아니라 입력 구조로 달성된다 — 매물 대리 호출에 손님 로그를 담을 필드가 아예 없다. 실행 후 입력을 되짚어 검사하는 방식이므로 "프롬프트에 그렇게 썼다"가 아니라 실제 유입 여부를 쟀다. (수용 기준 3)

6.3 데이터셋 무결성 통과

검사	결과
빈 DB에 migrate 001~010 순차 적용	성공 (PostgreSQL 16)
기존 스키마에 010만 전진 적용	성공
재적재 시 멍등성	고유 제약 위반으로 실패하고 건수 불변 — 롤백 정상
화자 귀속 (verify.sql 2번)	케이스 로그 55건 전부 관계에 귀속
참조 정합성 (verify.sql 8번)	관계에 없는 화자를 가리키는 로그 0건
개인정보 — 전화번호 대역	미할당 010-0 대역 위반 0건

06 시험 결과 — 실측 (계속)

6.4 API-only 슬라이스 (본 저장소) 통과

항목	확인 대상	결과
A-1	F3가 죽어도 F1은 산다 (수용 기준 15)	F1 목록 정상 응답, F3만 503 AI_UNAVAILABLE . AI 설정이 없어도 애플리케이션이 기동하고 장부 기능이 그대로다
A-2	없는 대상	404 NOT_FOUND . 다른 사무소 소유 식별자도 403이 아니라 404 (존재 여부 누설 차단)
A-3	대상은 정확히 하나	양쪽 동시 지정 · 아무것도 미지정 모두 422
A-4	인증 · CSRF	CSRF 없음 403 · 세션 없음 401

6.5 저장소 자동화 테스트 부분 통과 · 다수 건너뛴

uv run pytest · 2026-08-28 · 로컬 실행. **통과 수보다 건너뛴 수가 중요하다** — 아래 표의 마지막 열을 먼저 본다.

모듈	수집	통과	실패	건너뛴	해석
ai	170	170	0	0	전량 실행·통과. F3 계약 · 판정 · 생성 · Provider · 구조화 출력 복구. 외부 의존이 없어 건너뛴 것이 없다
backend	476	178	1	297	TEST_DB_URL 미설정으로 PostgreSQL 통합 테스트 297건(62.4%)이 실행되지 않았다 . 실제로 검증된 것은 순수 단위·계약 경로뿐이다
infra			미실행		배포·환경 렌더링 계약. 이번 보고 범위 밖
합계	646	348	1	297	—

실패 1건 — 원인과 조치

tests/integration/test_anchor_card_generation.py::test_every_open_trade_type_is_stored_in_the_price_child_table 같은 파일의 테스트 23개 중 **이 하나만 @requires_database 마커가 빠져** 있어, DB가 없는 환경에서도 실행되어 실패했다. 나머지 22개는 정상적으로 건너뛰었다. **제품 결함이 아니라 테스트 하네스 결함**이며, 마커를 추가해 조치했다. 다만 이 테스트가 실제 PostgreSQL에서 통과하는지는 아직 확인되지 않았다 — 297건 건너뛴에 함께 묶인다.

이 결과가 말하는 것

"348건 통과"를 성과로 읽으면 안 된다. **F3의 핵심 경로(앵커 카드 생성·저장, 후보 선정, 중개 판정, 실행 선정, 마이그레이션)는 전부 DB 통합 테스트에 들어 있고, 그것이 통째로 실행되지 않았다**. 현재 자동으로 지켜지고 있는 것은 **계약과 순수 로직**이며, 데이터 경로는 6.1·6.3의 수동 검증이 대신하고 있다.

재현 — 6.1·6.2 cd 06_프로토타입_F3플로우 && python run.py · 6.3 psql -f data/verify.sql · 6.4 SCENARIOS.md A군 · 6.5 uv run pytest (ai · backend)

07 미측정 항목과 차단 사유

빈칸을 추정치로 채우지 않는다. 각 항목에 무엇이 없어서 못 했는지와 무엇이 갖춰지면 측정이 시작되는지를 적는다.

#	미측정 지표	차단 사유	측정 개시 선행 조건
1	포지션 카드 근거 지지율 90% (수용 기준 2)	실제 모델로 생성한 카드 표본이 없다. 현재 결과는 전부 mock 참조 구현이며 모델 품질을 말해 주지 않는다	Provider 키를 넣고 전체 파이프라인으로 20건 생성 → negotiation_position_evidence 에서 QUOTE 가 원본 interaction_id 를 가리키는 비율 집계
2	단일 프롬프트 대비 블라인드 선택 60% (수용 기준 4)	기준선 경로가 온라인 구성도에 없다. 비교 대상이 없으면 비교 수치를 만들 수 없다	양측 자료를 한 번에 받아 판정을 내는 단일 프롬프트 경로 추가 + 동일 스냅샷·모델 계열 고정 + 구성 이름 제거·A/B 무작위화
3	DB 통합 테스트 297건 (backend의 62.4%)	TEST_DB_URL 미설정으로 로컬 실행에서 통째로 건너뛰어졌다. 더해서 CI에 테스트 실행 워크플로가 없어 (현행 3종은 Discord 알림·PR 정책 검토) 통과 이력이 자동으로 축적되지 않는다	로컬 PostgreSQL 기동 + TEST_DB_URL 지정 후 재실행. 이후 PR 단위로 실행되는 워크플로를 추가해 건너뛴 수까지 이력에 남게 함
4	응답 시간 5초 (수용 기준 8)	MVP 요구사항 5장 비기능에 성능 요구가 0건 이라 승인된 임계값이 없고, 측정 환경(부하 조건·데이터 규모)도 고정되지 않았다	비기능 요구에 응답시간 항목 등재 + performance 분할 (7,200행 규모) 확보 후 단계별 지연 계측
5	후보 SQL 일치율 100% (본 저장소 기준)	프로토타입에서는 일치하지만 본 저장소 실행 결과와의 대조가 아직 없다. 하네스(case_check_api.py)는 준비되어 있으나 미실행	로컬 PostgreSQL + 시드 적재 + Backend 기동 후 하네스 실행. 갈린 케이스는 코드/모델 판별 규칙(2장)으로 원인 분리
6	종단간 5회 연속 성공	Worker 기동 + Provider 키가 필요한 전체 파이프라인을 아직 반복 실행하지 않았다	전체 파이프라인 1회 성공 확인 후 동일 입력 5회 반복, 실패·재시도 건을 제외하지 않고 집계
7	비식별 현업 사례 기반 품질 결론	협조 중개사 정답 쌍이 아직 없다. 합성 데이터만으로 현업 분포에 대한 결론을 내지 않는다 는 원칙에 걸린다	개인정보 처리 근거·반출 승인 확보 → 비식별 검수 → hidden final 분할에 편입
8	A-1-3 · A-3-3의 본 저장소 재현	가격 인하는 PATCH 로 장부를 바꿔야 재현되고, 관계 수정 API가 아직 없다. 하네스는 읽기 전용이다	되돌릴 계획을 세운 뒤 수동 PATCH, 또는 시드 재적재를 전제로 한 파괴적 시나리오 분리

지금 결과로 말할 수 있는 것과 말할 수 없는 것

말할 수 있는 것 — 판정 규칙(게이트 · 5축 · 등급 · 날짜 산출)이 A군 13케이스에서 의도대로 작동하고, 대리 격리가 입력 구조로 성립하며, 데이터셋에 화자 귀속·참조 정합성 문제가 없고, F3 장애가 F1으로 번지지 않는다.

말할 수 없는 것 — 실제 모델이 화자 규칙을 지키는지, 멀티 에이전트 구조가 단일 프롬프트보다 나은지, 5초 목표를 만족하는지. 이 세 가지는 **측정되지 않았으므로 발표에서 주장하지 않는다.**

08 타당성 위협과 한계

위협	내용	완화 방법
합성 데이터 편향	장부와 케이스 로그를 판정이 갈리도록 설계 했다. 현업 분포보다 결정적 진술이 조밀할 수 있다	배경 로그 112건은 합성 상담로그 데이터셋의 실제 문장을 사용. 최종 품질 결론은 승인된 비식별 현업 사례 확보 전까지 유보
mock을 품질 근거로 오독	mock은 규칙 R1~R4의 참조 구현이다. mock 통과는 규칙의 정합성 을 뜻하지 모델 성능이 아니다	결과표에서 mock 실행과 실모델 실행을 분리 표기. 실모델 카드가 mock에서 크게 벗어나면 프롬프트를 의심할 근거로만 사용
표본 크기	20건에서 60% 선호는 p ≈ 0.25 로 유의하지 않다	신뢰구간과 함께 보고. 방향 지표로만 사용하고 "우수함이 입증됐다"고 쓰지 않는다
평가자 1인	평가자 간 일치도를 제공할 수 없다	rubric을 사전에 고정하고 평가 후 기준을 바꾸지 않는다. 변경 시 새 라벨 버전 발행 및 기존 보고서 보존
정답이 하나가 아닌 항목	중개 판정 문장은 정답을 고정할 수 없다	허용 가능한 판단 범위와 rubric으로 관리. 빈 값 · 정보 없음 · 판단 불가 · 라벨 누락을 같은 상태로 합치지 않는다
미해결 데이터 가정	구표기 ㉠㉢와 ㉠㉡의 동일 인물 여부(45건)와 인덱스 없는 로그의 귀속(20건)은 현재 가정 이다	가정을 데이터에 표시해 두고(legacy_idx · 주? 키) 협조 중개사 확인 시 재생성
통과 수의 착시	backend 테스트의 62.4%가 기본 실행에서 건너뛰어진다 . 통과 수만 보면 검증 범위를 과대평가하게 된다	결과를 항상 수집 · 통과 · 실패 · 건너뛴 네 수치로 보고한다. 통과율 단독 인용 금지
캐시의 휘발성	프로토타입 캐시는 프로세스 내 디렉터리라 재시작하면 사라진다	수용 기준 13의 정식 검증은 본 저장소의 영속 캐시 키(로그 건수 · 최종 로그 시각) 기준으로 수행

버전 추적

모든 결과는 다음 사슬로 되짚을 수 있어야 하며, 이 보고서의 결과에도 같은 규칙을 적용한다.

요구사항 · 라벨 가이드 → dataset_version + manifest → search_config + embedding_version
→ model + prompt + workflow_version → evaluation_contract → report_id → 팀 수동 검토 기록 → 온라인 구성 이력

온라인 구성은 보고서 검토 후 **수동으로** 적용한다. 운영 결과가 데이터셋·프롬프트·온라인 구성으로 자동 반영되는 루프는 두지 않는다. 구성 변경이 품질이나 개인정보 정책을 악화시키면 직전 승인 구성으로 되돌릴 수 있도록 현재와 직전 구성을 식별해 보존한다.

이 보고서의 상태

v1.0은 **계획 확정 + 결과 부분 확보** 단계다. 7장의 8개 항목이 채워지면 v2.0으로 개정하며, 그때까지 이 문서의 어떤 수치도 최종 품질 결론으로 인용하지 않는다.